STT-7360 Méthodes biostatistiques

Proposition de plan pour la session d'hiver 2027
Cours orienté vers la formation à la recherche (maîtrise et doctorat)

Julien Miron

Version de travail — 13 octobre 2026

En bref

Le plan conserve l'ossature du cours d'hiver 2026 (rappels, simulations, données corrélées, théorie semi-paramétrique, données manquantes, erreur de mesure et échantillonnage à deux phases, tests multiples, trois études de cas, présentations d'articles). Il déplace toutefois le centre de gravité de l'*acquisition de méthodes* vers l'*exercice du métier de chercheur* : lire un article méthodologique de façon critique, en reproduire les résultats, évaluer une méthode par simulation, rédiger, arbitrer et présenter. L'examen final est remplacé (ou allégé) par un mini-projet de recherche qui s'étend sur toute la session.

1 Objectifs de formation

À la fin du cours, l'étudiante ou l'étudiant devrait pouvoir :

O1. **Lire** un article méthodologique en biostatistique et en extraire la structure (problème, modèle, estimateur, hypothèses, propriétés, validation) à l'aide d'une *fiche des caractéristiques méthodologiques*.

O2. **Reproduire** les résultats numériques d'un article (analyse de données et simulations) dans un flux de travail reproductible (R, Quarto/R Markdown, Git).

O3. **Concevoir** une étude de simulation rigoureuse (cadre ADEMP : objectifs, mécanisme générateur, estimand, méthodes, mesures de performance) et en rapporter l'erreur Monte Carlo.

O4. **Mobiliser** les outils théoriques transversaux (fonction d'influence, équations d'estimation, estimateurs sandwich, efficacité semi-paramétrique) pour comprendre *pourquoi* une méthode fonctionne et quand elle échoue.

O5. **Choisir et justifier** une méthode pour des données corrélées, incomplètes, mesurées avec erreur ou soumises à de la multiplicité.

O6. **Communiquer** : rédiger un court article, produire un rapport d'arbitrage et présenter oralement un travail de recherche.

2 Principes pédagogiques

— **Un fil conducteur : « de l'article à la méthode, de la méthode à la question ouverte ».** Chaque bloc thématique se termine par une question de recherche plausible (limite d'une méthode, hypothèse non vérifiée, extension naturelle).

— **La simulation comme outil de recherche**, introduite dès la 2e semaine et réutilisée dans toutes les études de cas et dans le projet.

— **La théorie comme langage commun.** La fonction d'influence sert de pont entre la robustesse, les équations d'estimation généralisées (GEE), la pondération par l'inverse de la probabilité et les méthodes ciblées (TMLE).

— **Deux parcours** (comme en 2026) : un tronc commun, puis des lectures et exercices supplémentaires plus théoriques pour le doctorat (Tsiatis, van der Laan et Rose, Jiang et Nguyen).

— **Classe active** : lectures préalables, courte présentation magistrale, puis discussion d'article ou atelier de programmation.

3 Calendrier proposé (15 semaines)

Les semaines sont numérotées ; la semaine de lecture est placée en semaine 9. M = tronc commun (maîtrise et doctorat), D = complément doctorat.

Sem.	Thème	Contenu et activités	Volet recherche / livrable
1	Introduction et rappels	Vraisemblance, modèles linéaires généralisés, inférence asymptotique (notes *Rappel*). Présentation du projet de session.	Atelier : flux de travail reproductible (Git, Quarto, `renv`).
2	Simulations	Principes, générateurs, cadre ADEMP, mesures de performance (biais, EQM, couverture), erreur Monte Carlo, parallélisation.	Exercice : critiquer la section « simulations » d'un article publié.
3	Données corrélées complexes (I)	Modèles mixtes linéaires et généralisés ; effet conditionnel vs marginal (Wu, ch. 2 ; Fitzmaurice et coll.). D : GAM mixtes, Jiang et Nguyen 3.5.2.	Devoir 1 (modèles mixtes, données BSI).
4	Données corrélées complexes (II)	GEE, estimateur sandwich, comparaison GEE/GLMM (articles Zhang et coll.).	Choix des articles à présenter.
5	**Étude de cas 1**	Neuhaus et McCulloch (2006) : corrélation entre effets aléatoires et covariables ; régression logistique conditionnelle (données `naisga`).	Fiche méthodologique + reproduction d'un tableau de l'article.
6	Théorie semi-paramétrique (I)	Fonction d'influence, M-estimateurs, robustesse (Wu, ch. 9 ; Tsiatis, ch. 3). Application : modèle mixte robuste (`SleepStudyRobuste.R`).	**Proposition de projet** (2 pages).
7	Théorie semi-paramétrique (II)	Équations d'estimation, GEE vues comme M-estimation, efficacité. D : Tsiatis, ch. 4 ; van der Laan et Rose, ch. 5.	Devoir 2 (GEE, pleuropneumonie).

Sem.	Thème	Contenu et activités	Volet recherche / livrable
8	**Étude de cas 2**	Méthodes ciblées pour variables continues (Tuglus et van der Laan) ; TMLE, découverte de biomarqueurs.	Fiche méthodologique + petite simulation comparant TMLE et régression.
9	*Semaine de lecture* — rencontres individuelles sur les projets		
10	Données manquantes (I)	Mécanismes MCAR/MAR/MNAR, imputation multiple (Wu, sect. 3.2–3.5).	Exercice d'imputation (données dentaires).
11	Données manquantes (II)	Pondération par l'inverse de la probabilité (IPW), estimateurs doublement robustes ; lien avec la fonction d'influence (Wu 10.3.1).	**Rapport d'étape** du projet (résultats préliminaires).
12	**Étude de cas 3**	Erreur de mesure et échantillonnage à deux phases (Breslow et Chatterjee, 1999 ; données NWTS). Comparaison d'estimateurs.	Fiche méthodologique + rapport d'arbitrage simulé de l'article.
13	Tests multiples	FWER, FDR, procédures pas-à-pas, rééchantillonnage (Farcomeni ; Dudoit et van der Laan, données ApoAI).	Résolution de problèmes en équipe.
14	Présentations d'articles	Présentations de 20 min + 10 min de discussion animée par un « arbitre » désigné.	Rapport d'arbitrage écrit (1–2 pages).
15	Colloque de fin de session	Présentations des projets (format congrès : 12 min + questions).	**Article final** (remis une semaine plus tard).

4 Le mini-projet de recherche (fil rouge de la session)

Format : « reproduire, puis étendre »

Chaque personne (ou équipe de deux à la maîtrise) choisit un article méthodologique récent, idéalement lié à son propre sujet de recherche, en reproduit un résultat clé, puis propose *une* extension évaluée par simulation ou par une petite dérivation théorique.

Exemples d'extensions.

- Évaluer la sensibilité d'un estimateur à une violation d'hypothèse (mauvaise spécification des effets aléatoires, MNAR, contamination par des valeurs aberrantes).
- Comparer la méthode de l'article à une alternative robuste ou doublement robuste.
- Dériver la fonction d'influence d'un estimateur et en tirer une variance sandwich, puis vérifier la couverture par simulation (D).
- Adapter la méthode à un autre type de réponse (binaire, ordinale, de comptage).

Pistes tirées de la liste d'articles 2026. Estimateur sandwich empirique pour la g-computation par espérances conditionnelles itérées (Talbot et coll.) ; ACP fonctionnelle comme alternative aux modèles mixtes (Ségalas et coll., 2024) ; modèles longitudinaux binomiaux et de comptage, GEE vs GLMM (Zhang et coll.) ; modèles mixtes avec erreur de mesure et M-estimateurs pour modèles mixtes (Wu, sect. 5.1–5.2 et 9.4).

Jalons.

Semaine	Livrable	Contenu attendu
6	Proposition	question, article de départ, estimand, plan de simulation ADEMP
9	Rencontre	validation du plan et du code de reproduction
11	Rapport d'étape	reproduction réussie ou écarts expliqués
15	Présentation	format congrès
16	Article	8–12 pages (maîtrise) ou 12–20 pages (doctorat), code public

5 Études de cas : format révisé

Les trois études de cas de 2026 sont conservées, mais chacune produit trois éléments courts :

1. la **fiche des caractéristiques méthodologiques** (déjà utilisée en 2026) ;
2. une **reproduction** d'un tableau ou d'une figure de l'article à partir des données fournies (`naisga.csv`, `genes_select`, données NWTS) ;
3. une **question ouverte** : une limite de l'article et une façon de l'étudier.

L'étude de cas 3 prend la forme d'un rapport d'arbitrage, afin d'exercer cette compétence avant les présentations d'articles.

6 Évaluation proposée

Élément	**Poids**	**Remarques**
Devoirs (2)	20 %	modèles mixtes ; GEE et sandwich
Études de cas (3)	25 %	fiche + reproduction + question ouverte
Présentation d'article et rapport d'arbitrage	15 %	évaluation croisée en partie
Projet de recherche	40 %	proposition 5 %, rapport d'étape 5 %, présentation 10 %, article 20 %

Variante : si l'on souhaite garder un examen final (comme en 2026), il peut remplacer l'article final (20 %) et porter surtout sur la théorie transversale (fonction d'influence, équations d'estimation, mécanismes de données manquantes). Les questions de pratique et l'examen 2023 existants peuvent servir de base.

Différenciation maîtrise / doctorat. Au doctorat : exercices théoriques supplémentaires (déjà prévus en 2026), article de projet plus long avec une composante théorique, et rôle d'arbitre principal lors des présentations.

7 Compétences de recherche transversales

Compétence	Où elle est travaillée
Lecture critique	fiches méthodologiques, études de cas, présentations
Reproductibilité	atelier de la semaine 1, reproductions, dépôt de code du projet
Simulation	semaine 2, études de cas 2 et 3, projet
Théorie	semaines 6–7 et 11 ; exercices doctorat
Rédaction scientifique	proposition, rapport d'étape, article final
Arbitrage	étude de cas 3, présentations d'articles
Communication orale	présentations d'articles, colloque de fin de session

8 Matériel à réutiliser ou à préparer

— **Réutilisable tel quel** (site Brio 2026) : notes *Rappel*, *Simulations*, *Équations d'estimation*, *Données manquantes*, exercices et solutionnaires (`.tex`, `.Rmd`), données des études de cas, examen 2023 et questions de pratique.

— **À adapter** : notes de cours en `.docx` (cours 3, semi-paramétrique, données manquantes, cours 10) à convertir en LaTeX/Quarto pour uniformiser ; mise à jour de la liste d'articles pour présentation.

— **À créer** : guide du projet (gabarit d'article et grille), gabarit de rapport d'arbitrage, gabarit ADEMP, grilles d'évaluation des présentations, gabarit de dépôt Git.

Références principales

Dudoit, S. et van der Laan, M. J. (2008). *Multiple Testing Procedures with Applications to Genomics*. Springer.

Fitzmaurice, G. M., Laird, N. M. et Ware, J. H. (2011). *Applied Longitudinal Analysis*, 2e éd. Wiley.

Jiang, J. et Nguyen, T. (2021). *Linear and Generalized Linear Mixed Models and Their Applications*, 2e éd. Springer.

Morris, T. P., White, I. R. et Crowther, M. J. (2019). Using simulation studies to evaluate statistical methods. *Statistics in Medicine*, 38, 2074–2102.

Tsiatis, A. A. (2006). *Semiparametric Theory and Missing Data*. Springer.

van der Laan, M. J. et Rose, S. (2011). *Targeted Learning*. Springer.

Wu, L. (2010). *Mixed Effects Models for Complex Data*. Chapman & Hall/CRC.

Articles des études de cas : Neuhaus et McCulloch (2006, *JRSS B*) ; Tuglus et van der Laan (2011) ; Breslow et Chatterjee (1999, *JRSS C*).